

零基础小白组员项目架构与现场操作指南

本指南专为另外三名未实际参与代码编写的组员（张杰、王婷、刘洋）定制。指南将复杂的计算机专业黑话翻译为通俗的大白话，详细解释了项目的全局图纸、代码目录中每一个文件的作用、以及每一条控制台命令在系统底层的工程含义，并为每个人负责的板块提供了傻瓜式操作指南，确保答辩演示完美成功。

一、大白话项目全局图纸（我们的系统是怎么跑起来的？）

我们可以把这个 RAG（检索增强生成）系统看作是一家“智能开卷考试辅助咨询公司”。整个系统由两大部分协同运行：

1. Streamlit 网页前台 (app/streamlit_app.py)：

这是公司精美的“接待前台”。用户在网页的聊天输入框里用最口语化的白话文输入问题。前台不负责计算，只负责把问题接过来传给后台大脑，并负责把最后生成的文字像打字机一样蹦出来，附带高亮展示引用文件来源。

2. Python 后端业务线 (src/)：

这是公司的“总机和参谋部”，内部分工高度严密。当用户问了一句“2025年的紧急通知写了什么？”，大脑会安排以下工作：

- 意图解析师 (src/query_parser.py)：先分析这句话，提取出核心搜索词为“紧急通知”，并剥离出限制条件“年份是 2025 年”。
- 特征翻译官 (scripts/embedding_server.py)：用远程 GPU 显卡（本地显卡太弱，去云端租用 4090 显卡）把问题翻译成 1024 维的数字向量（门牌号）。
- 图书管理员 (src/embed_store.py)：拿着门牌号去向量数据库里算距离，把 2025 年标签下相似度前 3 名的原文分块捞出来。
- 答案合成师 (src/qa.py)：把这 3 段召回的真实原文拼在一起，附带“不许胡说八道”的硬约束，喂给大模型 API 合成出带上标引用的最终答案。

二、代码目录生词本（我们这几百行代码都放在哪了？）

答辩时如果老师让你在文件夹里指出代码文件，请对照下面这张大白话文件定位导航生词表：

app/streamlit_app.py [前端]： 网页前台展示层。精美对话界面与侧边栏调试开关的代码所在处。

src/ [核心后端]： 核心大脑。包含 ingest 读取、preprocess 清洗、embed_store 向量入库、query_parser 意图解析和 qa 答案合成，职责非常清晰。

tests/ [测试代码]： 自动化测试实验室。内含 82 个离线 Mock 模拟测试用例，校验核心组件的鲁棒性。

scripts/ [辅助脚本]： 辅助工具箱。包含 AutoDL 云端部署脚本 setup_autodl.sh 和 FastAPI 向量特征服务器脚本等。

data/ [原始数据]： 数据档案馆。存放维基百科语料采集 wiki.jsonl 以及清洗后的 markdown 原始文本数据。

vector_store/ [向量数据库]： 向量数据库物理存储目录。ChromaDB 数据存在这里，由元数据 SQLite 文件和向量 Parquet 组成。

.env [钥匙配置]： 配置文件。存放 API Key 大门钥匙和配置，决定是 local 本地特征提取还是 remote 云端显卡卸载。

requirements.txt [包清单]： 依赖包清单。记录了项目所需的所有第三方 Python 库，用于环境一键搭建安装。

三、终端命令（小黑窗）与运行环境速成

1. 怎么在项目目录里打开小黑窗？

在 Windows 资源管理器中双击打开项目根目录 final_exam2 文件夹，按住键盘上的 Shift 键不要松开，在空白处点击鼠标右键，在弹出的右键菜单中选择「在此处打开 PowerShell 窗口」。

2. 一键依赖安装命令与后台含义

把整个项目的 Python 运行依赖库自动下载并安装到电脑上，就像按清单买齐所有佐料：

一键 Python 库依赖快速安装

运行命令： `pip install -r requirements.txt`

工程含义： 根据清单自动从清华或阿里国内镜像源，一键下载并安装诸如 Streamlit、ChromaDB、FPDF2、BeautifulSoup 等核心开发包。

3. 配置文件钥匙卡的大白话含义

记事本打开 .env 钥匙配置文件，配置使用本地 sentence-transformers 还是云端 RTX 4090 算力卸载服务：

系统开关配置文件 .env

运行命令： `OPENAI_API_KEY=sk-xxxx... OPENAI_EMBEDDING_MODEL=remote
OPENAI_EMBEDDING_BASE_URL=https://u12345-6008.seetacloud.com/v1`

工程含义： 配置云端大模型 API 钥匙卡，启用云端嵌入 remote 模式，并提供 AutoDL 云端 RTX 4090 的公网访问端口地址。

四、组员专区 — 动作步骤、运行命令与其后台工程含义

数据工程师：张杰 — 语料采集、清洗与云端 GPU 算力卸载操作

张杰同学负责多源高质量语料的采集和数据消噪清洗，并负责在 AutoDL 上部署加载 BAAI/bge 中文特征向量模型。

任务一：启动多源语料抓取与 BeautifulSoup/html2text 清洗 运行以下抓取清洗指令，并在浏览器或文件夹展示抓取生成的 markdown 文件。

启动爬虫引擎与数据清洗

运行命令： `python src/collect_corpus.py`

工程含义： 程序利用 requests 和 BeautifulSoup 抓取维基百科术语，并用 html2text 去除网页中 90% 以上的非语义噪点（如导航、广告），自动生成极其纯净的 Markdown 文本块并归档在 data 目录下。

任务二：一键部署并拉起云端 RTX 4090 GPU 嵌入服务 登录租用的 RTX 4090 显卡服务器，执行一键部署脚本拉起嵌入服务。

AutoDL 端一键拉起 GPU 特征服务

运行命令： `bash setup_autodl.sh`

工程含义： 在云服务器上安装 PyTorch 深度学习框架和依赖包，从 Hugging Face 镜像站下载 1024 维的高端 bge-large-zh 模型并加载到 GPU 显存中，暴露 FastAPI 服务接口静待本地数据发送。

任务三：百万数据一键云端算力卸载向量建库 运行本地建库命令，将百万级原始文本通过 POST 发送给云端 4090 并入库本地 ChromaDB。

百万数据云端卸载建库

运行命令： `python -m src.main build --metadata-strategy jsonl_only`

工程含义： 读取 data 目录下 1,000,176 行大文本，切成 1,215,021 个语义 Chunk。打包通过 HTTP POST 并发送到 AutoDL RTX 4090 云端，利用 4090 显卡算力将文本转化为特征向量（门牌号），本地拿到后 upsert 写入 ChromaDB 库。仅耗时 2.5 小时，耗费 4.70 元租用费！

前端交互工程师：王婷 — Streamlit UI 交互与安全网关演示操作

王婷同学负责一键将网页前台运行起来，并在浏览器上现场演示智能意图分类、调试看板以及输入安全拦截防御。

任务一：一键启动 Streamlit 智能问答对话前台网页 运行 Streamlit 启动命令，网页会自动在默认浏览器中弹出来。

本地一键拉起 Web 网页前台

运行命令： `streamlit run app/streamlit_app.py`

工程含义： 在本地启动一个轻量网页服务器，占用端口 8501 并自动弹出带有气泡聊天、打字机流式字元输出、以及玻璃盒调试看板的现代拟物化 Web 交互界面。

任务二：现场演示「打开玻璃盒」智能意图元数据过滤看板 勾选侧边栏「调试模式」，提问并现场向老师展示解析出的结构化 JSON 过滤字典。

开启调试侧边抽屉面板

运行命令： 勾选网页侧边栏「调试模式」按钮并提问

工程含义： 后台 query_parser.py 瞬间提取用户问题的意图，拆解为 search_query 语义词与 filters 元数据过滤条件 JSON 并在侧边栏高亮呈现，证明系统并非黑盒，而是具有高度精准的结构化过滤性能。

任务三：演示注入恶意代码前台 HTML 安全转义网关拦截 前台输入恶意 HTML 脚本或 Prompt 注入指令，现场演示系统不受攻击、转义转义安全的特性。

前台输入恶意代码并录入知识库

运行命令： 在增量数据录入框输入：<script>alert('黑客攻击')</script>这是一篇注入文档

工程含义： 文档以 upsert 动态录入并由 ChromaDB 召回。王婷在前端变量渲染输出前强引入 html.escape() 安全逃逸转义。前台网页将恶意标签转为无害实体字符直接输出显示，脚本绝对无法被浏览器执行，构筑了高安全沙箱网关。

测试与保障工程师：刘洋 — Pytest 自动化测试与物理容灾快照操作

刘洋同学负责在发版前一键执行 82 个自动化测试，并负责数据库的物理快照压缩备份与故障秒级原地复活。

任务一：一键跑通 82 个断网高保真 Mock 自动化测试用例 一键运行全量 Pytest 测试。在控制台展示 82 个测试用例 100% 通过的绿色画面。

一键启动 Pytest 自动化校验实验室

运行命令： `python -m pytest tests/ -v`

工程含义： 运行 Pytest，利用 `unittest.mock.patch` 对所有 OpenAI 和 ChromaDB 接口进行高保真离线 Mock 模拟，拦截网络开销，在 2.5 秒内 100% 成功通过全套 82 个测试用例，证明代码拥有极高健壮性。

任务二：将 ChromaDB 本地物理数据库打包为 5.8GB 容灾快照 运行打包压缩命令，把 5.8GB 的数据库物理实体瞬间归档备份，免去漫长的重复建库开销。

对本地 `vector_store` 目录进行物理压缩归档

运行命令： `tar -czvf vector_store_backup.tar.gz vector_store/`

工程含义： ChromaDB 底层是 SQLite 关系元数据和 Parquet 向量磁盘文件。这行命令直接对该持久化文件夹进行物理压缩，生成 `vector_store_backup.tar.gz` 容灾备份快照，可进行云端极速备份。

任务三：模拟数据库硬盘损坏故障并执行 1秒秒级灾备复原 现场在文件夹中删除 `vector_store` 目录模拟数据损坏，一键解包在 1秒内满状态原地复活系统。

解压缩容灾快照执行秒级原地复活

运行命令： `tar -xzvf vector_store_backup.tar.gz`

工程含义： 一旦数据库断电死锁、数据损坏或误删除，直接在命令行一键解包，在 1 秒内从物理快照镜像中原地重构完整的 `vector_store/` 目录，网页刷新即可继续完美对话，无需重跑 2.5 小时！